Detección Automatizada y Explicativa de Neumonía a partir de Imágenes de Tórax mediante Redes Neuronales Convolucionales

Amaya Zabala, Daniel[1]; Quiroga Barrios, Diego Armando[1]; Rodríguez Romero, Lina Jomara[1]; Urbina González, Daniel Leonardo[1].

[1]Samsung Innovation Campus (SIC) 2024, Universidad El Rosario, Bogotá, Colombia.

Resumen:
Este trabajo presenta el desarrollo de un sistema de inteligencia artificial para detectar y clasificar neumonía en radiografías de tórax pediátricas, diferenciando entre neumonía bacteriana, neumonía vírica y casos normales. Se evaluaron diferentes aproximaciones metodológicas, como la segmentación de bordes, la clusterización no supervisada, la segmentación anatómica con U-Net y la generación de datos sintéticos mediante GANs. El enfoque final utilizó el etiquetado explícito de clases, el equilibrio del conjunto de datos mediante imágenes generadas artificialmente y una arquitectura VGG16 preentrenada. Este modelo funcionó con solidez, con un 87.18 % de precisión en el conjunto de pruebas y métricas favorables por clase. Además, se exploró el uso de Grad-CAM para generar visualizaciones explicativas que indicaran las regiones pulmonares que más influyen en la predicción. Aunque la integración completa de esta herramienta sigue siendo para un trabajo futuro, los resultados sugieren que puede complementar el análisis automatizado y apoyar la validación clínica de forma preliminar.

Palabras Clave: Neumonía pediátrica, Redes neuronales convolucionales (CNN), U-net, GANs, VGG16, Grad-Cam, Diagnóstico asistido por inteligencia artificial.

1 Introducción

1.1 Contextualización del problema

La neumonía es una enfermedad infecciosa que afecta los pulmones y sigue siendo una de las principales causas de morbilidad y mortalidad infantil en todo el mundo, especialmente en países con recursos limitados (World Health Organization, 2022). Se trata de una condición en la que los sacos alveolares se inflaman y se llenan de líquido o pus, lo que dificulta la correcta oxigenación del cuerpo y provoca síntomas como tos, fiebre y dificultad respiratoria.

El diagnóstico oportuno es crucial para mejorar los desenlaces clínicos, pero interpretar radiografías de tórax —principal herramienta diagnóstica— requiere experiencia especializada y puede verse afectado por la subjetividad del observador. Esto plantea la necesidad de desarrollar herramientas de apoyo automatizadas que contribuyan a reducir los errores y agilizar la toma de decisiones médicas.

No todas las neumonías son iguales y su origen (bacteriano o viral) determina tanto el tratamiento como el pronóstico. Por eso, es fundamental que los modelos de inteligencia artificial puedan no solo detectar la presencia de neumonía, sino también diferenciar sus tipos. Las diferencias radiográficas son clave para sustentar el proceso de etiquetado manual en este proyecto.

- **Neumonía Bacteriana:** Suele presentarse en las radiografías como áreas blancas muy bien delimitadas (consolidación lobar), típicamente localizadas en un solo segmento o lóbulo pulmonar. Estas consolidaciones muestran bordes definidos y a menudo se acompañan de broncogramas aéreos, que son estructuras tubulares negras visibles dentro de la zona blanca de la consolidación (Franquet, 2001).

- **Neumonía Viral:** Tiende a manifestarse con opacidades más difusas y mal definidas, especialmente en las zonas centrales. Estas opacidades tienen un aspecto más "algodonoso", lo que refleja inflamación intersticial más que consolidación alveolar densa (Kim et al., 2002). Este patrón es más extendido y afecta varias regiones del pulmón, lo que se ha considerado como criterio visual al etiquetar las imágenes de neumonía viral.

Estas diferencias permitieron realizar un etiquetado manual responsable y fundamentado de las imágenes contenidas en el *dataset Chest X-Ray Images (Pneumonia)* disponible en *Kaggle* (Mooney, 2018). Este conjunto de datos incluye radiografías de tórax pediátricas, lo que acentúa la necesidad de interpretar correctamente los patrones, dado que las presentaciones radiográficas en niños pueden diferir de las de adultos.

1.2 Planteamiento del problema

Tradicionalmente, los modelos de inteligencia artificial aplicados a este tipo de diagnóstico se han centrado en clasificaciones binarias, es decir, diferenciar simplemente entre neumonía y no neumonía. Sin embargo, esta aproximación resulta insuficiente para las necesidades clínicas, ya que no proporciona información sobre el tipo específico de neumonía, lo que es crucial para iniciar el tratamiento adecuado (antibióticos para bacteriana, tratamiento de soporte para viral).

Por esta razón, el presente proyecto se enfoca en la clasificación multiclase, donde el modelo debe ser capaz de distinguir entre neumonía bacteriana, neumonía viral y casos normales. Este enfoque no solo es más complejo desde el punto de vista computacional, sino que también genera mayor valor clínico al proporcionar diagnósticos más específicos.

1.3 Relevancia del uso de las Redes Neuronales Convolucionales (CNN)

Las redes neuronales convolucionales (CNN) han demostrado ser altamente eficaces en la clasificación de imágenes médicas debido a su capacidad para aprender automáticamente las características visuales relevantes sin necesidad de diseñarlas

manualmente (Litjens et al., 2017).

Además, el uso de modelos preentrenados como InceptionV3 o Xception, combinado con técnicas de aprendizaje por transferencia, permite adaptar arquitecturas complejas a problemas específicos como el planteado, incluso cuando se dispone de un volumen limitado de datos etiquetados (Rajpurkar et al., 2017).

La integración de herramientas de explicabilidad como *Grad-CAM* es especialmente relevante, ya que proporciona mapas de calor que destacan las zonas pulmonares que influyeron en la predicción, facilitando la validación clínica y aumentando la confianza en el modelo (Selvaraju et al., 2017).

1.4 Objetivo

Por esta razón, el propósito de este proyecto es desarrollar un sistema de inteligencia artificial basado en redes neuronales convolucionales que permita clasificar imágenes de radiografías de tórax pediátricas en tres categorías: neumonía bacteriana, neumonía viral y casos normales. El modelo no solo deberá proporcionar la clasificación, sino también ofrecer explicaciones visuales que resalten las áreas de la imagen que sustentan la decisión, lo que contribuirá a facilitar su adopción clínica como herramienta de apoyo al diagnóstico.

2 Metodología

El desarrollo del presente proyecto se llevó a cabo en múltiples etapas, iniciando con un análisis exploratorio de datos, seguido por varios enfoques de preprocesamiento, segmentación, balanceo y clusterización. Aunque varios procedimientos fueron explorados, finalmente se adoptó una metodología diferente que logró superar los problemas observados en los enfoques anteriores. A continuación, se describen en detalle tanto las estrategias implementadas durante el desarrollo como la metodología definitiva que resultó ser efectiva.

2.1 Análisis Exploratorio de Datos (EDA)

2.1.1 Carga y revisión de imágenes: Se realizó la importación y organización de las imágenes provenientes del *dataset Chest X-Ray Images (Pneumonia)*, estructurado en carpetas para los conjuntos de entrenamiento, validación y prueba.

Se diseñó una función personalizada para: a). Verificar la cantidad de imágenes por conjunto. b). Confirmar la escala de grises y la consistencia de los tamaños. c). Identificar imágenes corruptas o con problemas de carga.

Posteriormente, se visualizaron imágenes aleatorias por clase para realizar una inspección visual preliminar de los patrones radiográficos característicos.

2.1.2 Redimensionamiento y normalización: Todas las imágenes se reescalaron a 224×224 píxeles y se convirtieron a matrices numéricas, normalizando los valores de píxeles al rango $[0, 1]$ para asegurar estabilidad durante el entrenamiento de modelos de aprendizaje profundo. Este tamaño se eligió como punto de equilibrio entre conservar suficiente calidad visual para el análisis radiográfico y reducir la carga computacional, permitiendo un procesamiento eficiente sin comprometer la información relevante de las imágenes.

2.2 Primera aproximación: Segmentación clásica, clusterización y balanceo clásico

2.2.1 Segmentación pulmonar: Con el objetivo de centrar la atención del modelo en las regiones anatómicas relevantes, se aplicó segmentación pulmonar mediante técnicas de binarización y filtrado por contraste. En casos específicos se emplearon máscaras basadas en operadores Sobel, Laplace y Canny. Esto permitió resaltar las zonas pulmonares y minimizar el ruido proveniente de estructuras externas como costillas o el diafragma.

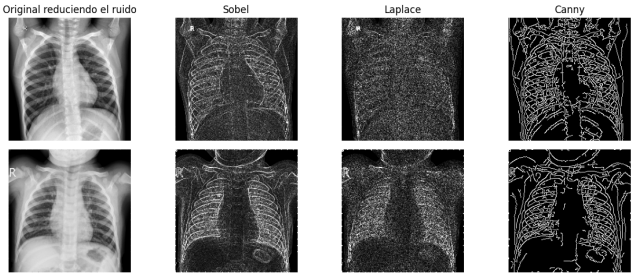


Figura 1. Comparación de los filtros Sobel, Laplace y Canny aplicados a imágenes de radiografía. Cada filtro resalta distintas características estructurales relevantes.

2.3 Aplicación de clusterización:

Se aplicó un enfoque de *clustering* no supervisado a las imágenes etiquetadas como "PNEUMONIA", con el fin de diferenciar entre casos bacterianos y virales, siguiendo los siguientes pasos:

1. Conversión de las imágenes a vectores unidimensionales (*flattening*).
2. Se redujeron las dimensiones con PCA *(Principal Component Analysis)* para facilitar la separación.
3. Se aplicó K-Means con visualización por t-SNE, identificando dos agrupaciones que respaldaban las etiquetas manuales.

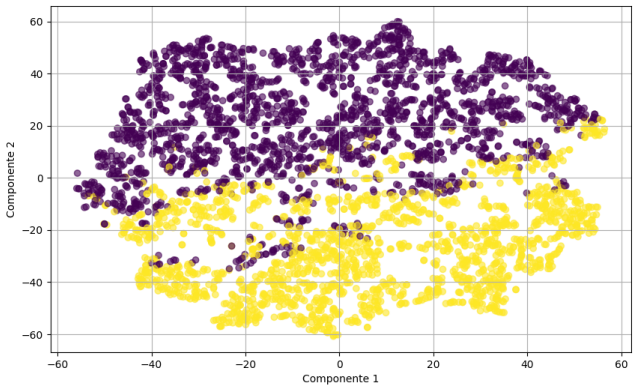


Figura 2. Representación *t-SNE* de las imágenes agrupadas mediante *K-Means*. Se observan dos clústeres diferenciados, lo que respalda la separación multiclase en el espacio de características. El coeficiente de silueta obtenido fue de 0.21 y el índice de Davies-Bouldin, 1.75.

2.4 Balanceo de clases

Se identificó un desequilibrio en la cantidad de muestras por clase, predominando los casos de neumonía bacteriana. Se intentó balancear el conjunto de datos mediante:

- Oversampling de la clase "NORMAL" con técnicas de *data augmentation* (rotaciones, escalamiento, desplazamientos).
- Undersampling aleatorio de la clase mayoritaria ("PNEUMONIA-BACTERIAL").

Clase	Originales	Eliminadas	Generadas	Total
Normal	1269	0	495	1764
Neumonía Viral	1764	0	0	1764
Neumonía Bacterial	2110	346	0	1764

Cuadro 1
Resumen del balanceo de clases: eliminación y generación de imágenes para igualar la cantidad entre clases.

Este primer enfoque no ofreció resultados satisfactorios al momento de implementar los modelos, por lo que fue descartado.

2.5 Segunda aproximación: Segmentación con redes U-Net, clusterización y balanceo clásico

Dado que los métodos de segmentación por bordes no fueron efectivos, se diseñó una nueva etapa de segmentación anatómica utilizando el *dataset CheXmask Database* (Gaggion et al., 2025), que contiene máscaras validadas para pulmones y corazón.

2.5.1 Segmentación con U-Net: Se entrenó un modelo U-Net con backbone ResNet34 utilizando las imágenes y máscaras anatómicas del *CheXmask*. Este modelo logró una alta precisión en la delimitación de los pulmones (IoU $>$ 0,94 en validación) y se utilizó para generar máscaras para todo el conjunto objetivo.

2.5.2 Aplicación de máscaras y visualización: Se aplicaron las nuevas máscaras para extraer automáticamente las regiones pulmonares en cada imagen, generando nuevas versiones segmentadas para todos los *splits*. Se comprobó visualmente su calidad mediante superposición de máscaras.

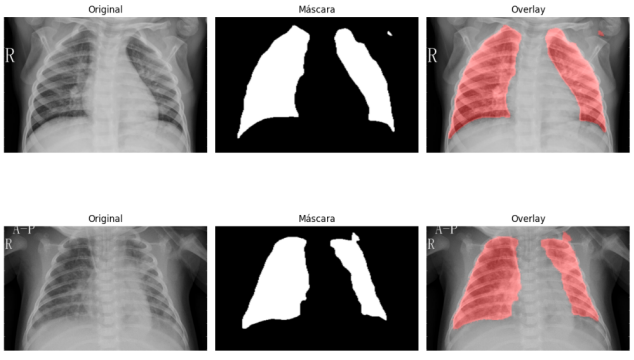


Figura 3. Segmentación pulmonar con U-Net: imagen original, máscara generada y superposición (*overlay*), usando el dataset *CheXmask*.

El propósito de integrar estas máscaras anatómicas fue proporcionar al modelo un contexto explícito de las zonas pulmonares, reduciendo el ruido proveniente de estructuras irrelevantes y mejorando el enfoque en áreas clínicamente significativas.

Aunque esta estrategia prometía mejorar el rendimiento de clasificación al dirigir la atención del modelo hacia las regiones pulmonares, los resultados obtenidos no mostraron mejoras significativas en comparación con los enfoques anteriores. A pesar de ello, esta aproximación demostró potencial para afinar el enfoque anatómico del modelo y aumentar la interpretabilidad clínica de sus predicciones, lo cual resulta valioso para desarrollos futuros en tareas de diagnóstico asistido por inteligencia artificial.

2.5.3 Clusterización y balanceo: Sobre estas nuevas imágenes segmentadas se volvió a aplicar el proceso de clusterización (PCA + K-Means) y el balanceo por *oversampling* y *undersampling*. Sin embargo, este segundo enfoque también resultó insuficiente, evidenciando problemas de generalización y precisión durante el entrenamiento.

2.6 Enfoque final, metodología definitiva

Tras evaluar los resultados anteriores, se optó por una nueva estrategia más simple y robusta que permitió alcanzar resultados exitosos:

2.6.1 Etiquetado multiclase a partir del nombre de archivo: En lugar de aplicar clusterización, las imágenes fueron etiquetadas automáticamente utilizando los nombres de archivo, que contienen información relevante. Por ejemplo:

- `person1_bacteria_1.jpeg` fue etiquetada como "PNEUMONIA-BACTERIAL".
- `person81_virus_152.jpeg` como "PNEUMONIA-VIRAL".

Esta estrategia permitió una clasificación más confiable sin ambigüedades.

2.6.2 Balanceo con redes generativas (GANs): Para resolver el desbalance de clases, se implementó un modelo de *Generative Adversarial Networks (GANs)* con el fin de sintetizar imágenes realistas de las clases minoritarias (Normal y Neumonía Viral). Este enfoque permitió aumentar la diversidad del conjunto de entrenamiento sin comprometer la coherencia visual, a diferencia de técnicas tradicionales de *data augmentation*.

Para la preparación del conjunto de datos, las imágenes originales se leyeron desde archivos JPEG, se convirtieron en tensores, redimensionadas a un tamaño uniforme y normalizadas al rango $[-1, 1]$. Se utilizó la API `tf.data` para mezclar, agrupar en lotes y optimizar la carga de datos durante el entrenamiento.

Luego, el entrenamiento se realizó por lotes, donde se añadió un leve ruido gaussiano a las imágenes reales para mejorar la estabilidad del discriminador. Los gradientes del generador y del discriminador se calcularon y aplicaron en cada iteración. Para garantizar continuidad, se implementó un sistema de *checkpoints* periódicos cada 10 épocas y se redujo la tasa de aprendizaje un 50 % al iniciar la fase de ajuste fino.

Una vez entrenado el modelo, se generaron imágenes sintéticas para igualar el número de ejemplos en cada clase con respecto a la

clase mayoritaria (PNEUMONIA-BACTERIAL). Para ello, por cada imagen faltante:

- Se generó un vector de ruido aleatorio con la etiqueta correspondiente.
- Se utilizó el generador congelado para producir la imagen.
- La imagen se reescaló al rango $[0, 255]$ y se guardó en formato JPEG en su carpeta correspondiente.

El balanceo final se resume en la Tabla 2, donde cada clase quedó con exactamente 2530 imágenes.

Clase	Imágenes reales	Imágenes generadas	Total
Normal	1269	1261	2530
Neumonía Viral	1345	1185	2530
Neumonía Bacterial	2530	0	2530

Cuadro 2
Resumen del balanceo de clases mediante GANs.

2.6.3 Sin segmentación: A diferencia de los enfoques anteriores, en esta versión no se utilizó segmentación pulmonar, ya que se evidenció que los modelos de clasificación multiclase aprendían mejor directamente a partir de las imágenes originales completas, aprovechando sus características globales.

La evolución metodológica de este proyecto refleja una exploración sistemática de múltiples enfoques, desde técnicas clásicas hasta soluciones basadas en inteligencia artificial avanzada como U-Net y GANs. Aunque se probaron técnicas sofisticadas de preprocesamiento y clusterización, la mejor solución resultó ser una combinación de etiquetado explícito y generación de datos sintéticos, lo que permitió obtener un conjunto balanceado y bien definido, ideal para el entrenamiento de modelos robustos de clasificación de neumonía.

2.7 Construcción y entrenamiento de las CNN

Durante el desarrollo del modelo se evaluaron tres arquitecturas profundas de redes neuronales convolucionales: DenseNet201, DenseNet121 y VGG16, todas con pesos preentrenados en ImageNet. Cada enfoque fue implementado mediante dos fases de entrenamiento consecutivas: una inicial con el modelo base congelado y una posterior de *fine-tuning* sobre capas superiores. Cada una de estas arquitecturas correspondió a una de las metodologías exploradas a lo largo del proyecto.

- **Primera arquitectura (DenseNet201):** Asociada a la primera aproximación basada en segmentación clásica, clusterización y balanceo convencional. Para el entrenamiento del modelo se utilizaron las imágenes segmentadas mostradas en la Figura 1, específicamente aquellas procesadas con el filtro Sobel, descartando las versiones obtenidas con los operadores Laplace y Canny debido a su bajo desempeño en las pruebas preliminares. Se utilizó una arquitectura DenseNet201 con cabeza personalizada, entrenamiento progresivo en dos fases, y aplicación de técnicas de regularización como *Dropout* y *BatchNormalization*. Aunque se obtuvo una precisión aceptable durante el entrenamiento, el modelo mostró una pérdida significativa de generalización al evaluarse con el conjunto de prueba, por lo que fue descartado como opción viable.

- **Segunda arquitectura (DenseNet121):** Corresponde a la segunda aproximación que incorporaba segmentación con redes U-Net, clusterización y balanceo clásico. En este caso, las imágenes utilizadas para el entrenamiento fueron las versiones segmentadas con máscaras anatómicas generadas por U-Net, como se muestra en la Figura 3. Estas máscaras permitieron delimitar de forma precisa las regiones pulmonares, centrándose en las zonas clínicamente relevantes. La arquitectura DenseNet121 fue enriquecida con módulos de atención tipo *Squeeze-and-Excitation* y convoluciones *DepthwiseConv2D*, buscando mejorar la capacidad del modelo para captar patrones locales. Aunque se observó un mayor *recall* en la detección de neumonía viral, la precisión global fue inferior al 50 % en el conjunto de prueba, evidenciando problemas de sobreajuste y limitaciones en su capacidad de generalización.

- **Tercera arquitectura (VGG16 - modelo definitivo):** Implementada dentro del enfoque final, esta configuración probó ser la más estable y eficiente. Se empleó una red VGG16 con pesos preentrenados en ImageNet, acompañada de una cabeza personalizada compuesta por capas *Flatten*, *Dense*, *Dropout* y *Softmax*. El modelo fue entrenado con datos balanceados mediante imágenes sintéticas generadas con GANs, sin segmentación pulmonar, en su versión original.

  El proceso de entrenamiento se dividió en dos fases: en la primera, se congeló la red base y se entrenó únicamente la cabeza del modelo durante 15 épocas, utilizando ponderación de clases para contrarrestar posibles desbalances residuales. En la segunda fase (fine-tuning), se descongelaron las últimas cuatro capas convolucionales de VGG16 y se continuó el entrenamiento por 10 épocas adicionales con una tasa de aprendizaje reducida.

  Se utilizó una estructura de directorios organizada en `train/`, `val/` y `test/`, imágenes RGB de 224×224 píxeles, un tamaño de lote de 32 y el optimizador Adam (1×10^{-4} en la fase 1 y 1×10^{-5} en la fase 2). Para controlar el sobreajuste y optimizar el aprendizaje, se emplearon los callbacks `ReduceLROnPlateau`, `EarlyStopping` y `ModelCheckpoint`, este último para guardar el mejor modelo bajo el nombre `best_vgg16.h5`.

En resumen, los modelos descartados ofrecieron aprendizajes clave en cuanto a sensibilidad, sobreajuste y efectos del desbalance, mientras que la arquitectura basada en VGG16 se consolidó como el modelo final por su solidez técnica y desempeño en escenarios clínicos simulados.

2.8 Construcción del modelo de interpretabilidad Grad-CAM

Con el objetivo de proporcionar interpretabilidad a las predicciones del modelo de clasificación, se implementó la técnica Grad-CAM *(Gradient-weighted Class Activation Mapping)*, la cual

permite visualizar las regiones de las imágenes que contribuyen de manera más significativa a las decisiones del modelo.

Durante la aplicación de Grad-CAM, se utilizó una arquitectura VGG16 preentrenada y ajustada, sobre la cual se generaron los mapas de activación clase-específicos. Las máscaras pulmonares previamente obtenidas se utilizaron para restringir el análisis del modelo exclusivamente a la región anatómicamente relevante, es decir, los pulmones. Esta integración permitió no solo reducir el ruido visual, sino también enfocar la interpretación del modelo sobre las zonas clínicamente significativas.

Los mapas de activación generados se superpusieron a las radiografías originales para facilitar la interpretación visual por parte de especialistas. Para distinguir claramente las clases predichas, se utilizó un esquema de codificación por colores: Rojo para neumonía bacteriana, verde pulmones sanos (casos normales) y azul para neumonía viral.

2.9 Recursos Utilizados

Recurso	Descripción
Python	Lenguaje de programación principal.
Pandas	Carga, manipulación y análisis de datos tabulares.
NumPy	Manipulación de matrices y operaciones numéricas.
Matplotlib	Visualización de imágenes y resultados.
Seaborn	Visualización estadística con gráficos atractivos y simplificados.
Scikit-learn	Aplicación de técnicas de reducción de dimensionalidad y clusterización.
TensorFlow/Keras	Desarrollo, entrenamiento y ajuste de modelos de *deep learning*.
Keras Tuner	Optimización automática de hiperparámetros.
Segmentation Models	Implementación de arquitecturas avanzadas de segmentación semántica.
Repositorio de GitHub	Repositorio que contiene el código fuente, scripts, configuraciones y documentación del proyecto desarrollado. Puede ser consultado en: `https://github.com/quirogaez/capstone`

Cuadro 3
Recursos utilizados y sus descripciones.

Además, todo el flujo de trabajo fue ejecutado en un entorno controlado y reproducible que aprovecha plenamente la aceleración por GPU. Para ello, se utilizó la imagen oficial `tensorflow/tensorflow:2.12.0-gpu`, que incluye Python 3.10, CUDA 11.8 y cuDNN 8.9 preinstalados. El contenedor se desplegó con `runtime: nvidia`, lo que permite que el *NVIDIA Container Toolkit* exponga directamente la GPU GeForce RTX 3060 Ti (arquitectura Ampere, capacidad computacional 8.6, 8 GB de memoria GDDR6) al entorno de ejecución de TensorFlow, sin necesidad de configurar manualmente los drivers dentro del contenedor. Al iniciar, se habilita un intérprete `bash` que instala JupyterLab en caliente, sin requerir token de acceso, facilitando así el trabajo interactivo mediante *notebooks*.

El sistema anfitrión corresponde a una estación de trabajo con Windows 10 Pro de 64 bits (build 19045), equipada con un procesador Intel Core i7-12700KF de 12ª generación (20 hilos, 3.6 GHz) y 32 GB de memoria RAM DDR4, lo que brinda una base sólida para tareas intensivas de cómputo y entrenamiento de modelos de aprendizaje profundo.

3 Resultados

3.1 Evaluación del Desempeño

El rendimiento de los modelos desarrollados se evaluó utilizando métricas estándar de clasificación multiclase: *accuracy*, *precision*, *recall* y *F1-score*, tanto de forma general como por clase. Estas métricas permiten valorar no solo la cantidad de predicciones correctas, sino también la capacidad del modelo para identificar adecuadamente cada categoría clínica, especialmente en un contexto médico donde los falsos negativos pueden tener consecuencias graves.

3.1.1 Comparativa entre arquitecturas: En la Tabla 4 se presenta un resumen del rendimiento alcanzado por cada una de las tres arquitecturas evaluadas: DenseNet201, DenseNet121 y VGG16. Como puede observarse, la arquitectura VGG16 superó a las demás en todas las métricas consideradas, consolidándose como el modelo final seleccionado.

Modelo	Accuracy	Precision	Recall	F1-score
DenseNet201	54.56 %	55.98 %	55.65 %	54.73 %
DenseNet121	46.79 %	48.98 %	42.59 %	40.06 %
VGG16	87.18 %	86.57 %	86.66 %	82.27 %

Cuadro 4
Comparativa de desempeño entre las arquitecturas CNN evaluadas en el conjunto de testeo.

3.1.2 Desempeño por clase: La Tabla 5 desglosa las métricas por clase para el modelo final (VGG16), proporcionando un análisis más detallado del comportamiento del clasificador frente a cada categoría: normal, neumonía bacteriana y neumonía viral.

Clase	Precision	Recall	F1-score
Normal	94.90 %	79.49 %	86.51 %
Neumonía Bacteriana	87.31 %	96.69 %	91.76 %
Neumonía Viral	77.50 %	83.78 %	80.52 %

Cuadro 5
Desempeño del modelo VGG16 por clase en el conjunto de testeo.

3.2 Matriz de Confusión

La matriz de confusión (Figura 4) permite visualizar el número de aciertos y errores cometidos por el modelo VGG16 en el conjunto de *test*. Se observa un excelente desempeño en la identificación de casos de neumonía bacteriana, con una tasa de aciertos superior al 97 %.

Sin embargo, las confusiones más frecuentes se producen entre las clases “Normal” y “Neumonía Viral”. En particular, 36 casos normales fueron clasificados erróneamente como virales, lo cual puede atribuirse a similitudes visuales entre ciertos patrones radiográficos leves, como opacidades difusas poco definidas.

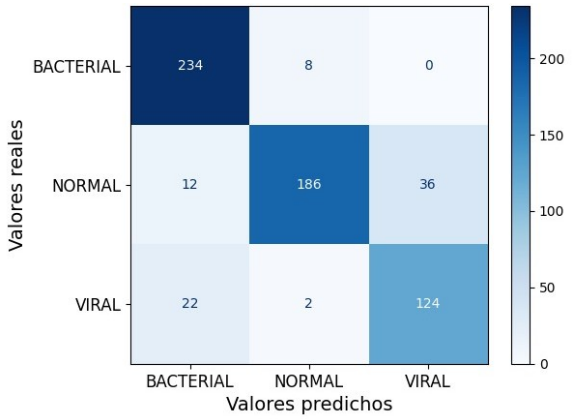


Figura 4. Matriz de confusión del modelo VGG16 en el conjunto de testeo.

3.3 Explicabilidad con Grad-CAM

Para facilitar la interpretabilidad clínica de las predicciones, se utilizó el método *Grad-CAM* para generar mapas de activación que muestran las regiones de la imagen que más influyeron en la decisión del modelo. La Figura 5 muestra ejemplos de imágenes representativas para cada clase, junto con sus respectivas visualizaciones de activación.

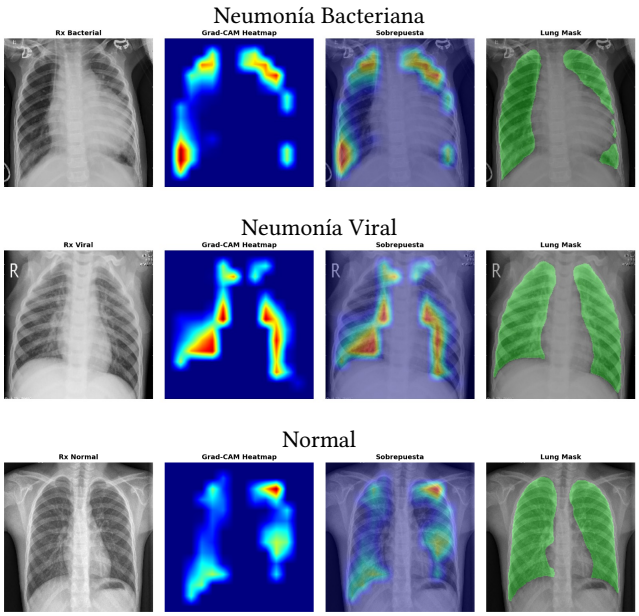


Figura 5. Visualización con Grad-CAM. Las áreas resaltadas indican las regiones pulmonares más influyentes para la clasificación.

Además, la Figura 5 muestra un ejemplo representativo del pipeline: imagen original, Grad-CAM, superposición final y máscara pulmonar. El Grad-CAM no solo permite una validación visual del modelo, sino que también sienta las bases para su posible adopción en contextos clínicos donde la interpretabilidad es un requisito esencial.

3.4 Análisis de errores

A pesar de su buen desempeño general, el modelo cometió errores principalmente en la distinción entre neumonía viral y casos normales. Esta confusión puede deberse a diversos factores:

- La sutileza de las opacidades virales, que a menudo se manifiestan como áreas difusas de difícil delimitación.
- La posible presencia de artefactos o variaciones anatómicas en radiografías normales que el modelo interpretó como patología.
- La calidad variable de las radiografías, que puede afectar la nitidez de los patrones intersticiales.

También se detectaron algunos errores en la clasificación de neumonía viral como bacteriana (22 casos), lo cual es comprensible dada la posible superposición de características visuales, especialmente cuando las infecciones virales presentan consolidaciones más marcadas de lo habitual. Sin embargo, los errores en la predicción de neumonía bacteriana fueron mínimos (solo 8 casos mal clasificados), lo que refuerza la solidez del modelo frente a esta clase.

En resumen, el modelo final basado en VGG16 logró un rendimiento sobresaliente en la tarea de clasificación multiclase de radiografías pediátricas de tórax. Gracias al uso de datos balanceados, redes preentrenadas y herramientas de explicabilidad como Grad-CAM, se obtuvo un sistema robusto y clínicamente interpretable que representa un avance significativo en el diagnóstico automatizado de neumonía.

4 Conclusiones

El presente proyecto logró desarrollar un sistema de inteligencia artificial capaz de clasificar radiografías pediátricas de tórax en tres categorías clínicas: neumonía bacteriana, neumonía viral y casos normales. A través de una exploración iterativa de distintas metodologías, se identificaron las estrategias más efectivas tanto desde el punto de vista técnico como clínico.

Inicialmente se evaluaron enfoques clásicos de segmentación, clusterización y balanceo de clases, así como técnicas más avanzadas como la segmentación anatómica con redes U-Net y la generación de imágenes con GANs. Estos métodos ofrecieron aprendizajes valiosos sobre los límites de generalización de los modelos y los desafíos asociados a la calidad de los datos médicos. Finalmente, el uso de etiquetado explícito, combinado con datos sintéticos generados por GANs y una arquitectura VGG16 preentrenada, permitió alcanzar un rendimiento sobresaliente en la tarea de clasificación multiclase, con un accuracy del 87.18 % y métricas robustas en todas las clases evaluadas.

El modelo demostró una alta capacidad para detectar neumonía bacteriana, con un F1-score del 91.76 %, y un rendimiento óptimo para la distinción entre neumonía viral y patrones normales, pese a las similitudes visuales que dificultan esta diferenciación. La integración de Grad-CAM aportó explicabilidad clínica, validando que las predicciones se basaban en regiones anatómicas relevantes.

Este proyecto representa un avance significativo hacia sistemas de apoyo al diagnóstico médico automatizado, especialmente

en contextos con recursos limitados. Entre las principales contribuciones se destaca el desarrollo de una solución multiclase y explicativa, el uso exitoso de datos generados sintéticamente para balanceo, y, la validación de modelos con métricas clínicas interpretables.

En lo que respecta a la proyección de la investigación para trabajos futuros, se propone la ampliación del modelo a la detección de otras patologías pulmonares, con el objetivo de evaluar su capacidad de generalización en escenarios clínicos más amplios. Asimismo, se plantea la necesidad de fortalecer el uso de técnicas de interpretabilidad, tales como Grad-CAM, mediante su integración sistemática para evaluar la relevancia de las regiones activadas, facilitar su validación clínica con expertos y explorar su incorporación en sistemas de apoyo a la toma de decisiones médicas que requieren explicaciones visuales claras y confiables.

Finalmente, este trabajo demuestra el potencial de las redes neuronales convolucionales como herramienta clínica y sienta las bases para futuras investigaciones en diagnóstico médico asistido por IA.

Referencias

Franquet, T. (2001). "Imaging of pneumonia: trends and algorithms". En: *European Respiratory Journal* 18.1, págs. 196-208. DOI: 10.1183/09031936.01.00213501. URL: https://publications.ersnet.org//content/erj/18/1/196.

Gaggion, N. et al. (2025). *CheXmask Database: a large-scale dataset of anatomical segmentation masks for chest x-ray images*. Ver. 1.0.0. PhysioNet. URL: https://physionet.org/content/chexmask-cxr-segmentation-data/1.0.0/Preprocessed/#files-panel.

Kim, Eun A et al. (oct. de 2002). "Viral Pneumonias in Adults: Radiologic and Pathologic Findings". En: *RadioGraphics* 22 (suppl$_1$), S137-S149. ISSN: 0271-5333. DOI: 10.1148/radiographics.22.suppl_1.g02oc15s137.

Litjens, Geert et al. (dic. de 2017). "A survey on deep learning in medical image analysis". En: *Medical Image Analysis* 42, págs. 60-88. ISSN: 13618415. DOI: 10.1016/j.media.2017.07.005.

Mooney, Paul (2018). *Chest X-Ray Images (Pneumonia)*. URL: https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia.

Rajpurkar, Pranav et al. (2017). *CheXNet: Radiologist-Level Pneumonia Detection on Chest X-Rays with Deep Learning*. arXiv: 1711.05225 [cs.CV]. URL: https://arxiv.org/abs/1711.05225.

Selvaraju, Ramprasaath R. et al. (oct. de 2017). "Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization". En: *2017 IEEE International Conference on Computer Vision (ICCV)*. IEEE, págs. 618-626. ISBN: 978-1-5386-1032-9. DOI: 10.1109/ICCV.2017.74.

World Health Organization (nov. de 2022). *Pneumonia in children*. URL: https://www.who.int/news-room/fact-sheets/detail/pneumonia.